UNIVERSIDADE FEDERAL DE UBERLÂNDIA

Disciplina: **Mineração de Dados**
Curso: **Ciência da Computação**
Professora: **Elaine Ribeiro Faria**

Trabalho Final

Tema: Classificação

Instruções:
1- Crie um relatório a partir das solicitações descritas a seguir.
2- Adicione um cabeçalho com a seguinte informação
Nome e nro de matrícula dos estudantes
3- Gere um arquivo pdf
4- Envie pelo Microsoft Teams

Objetivo:
Aplicar, avaliar e comparar algoritmos de classificação supervisionada em uma base de dados real, desenvolvendo habilidades de exploração e preparação dos dados, aplicação de algoritmos de classificação, avaliação de desempenho e interpretação dos resultados.

1- Base de Dados
Cada grupo deverá escolher uma base de dados pública dentre a lista de bases de dados listada no fim deste enunciado. Assim que o grupo enviar para o professor o nome dos integrantes, o professor indicará a base disponível, seguindo uma ordem sequencial.

Também será possível propor outra base de dados pública ou uma base própria, desde que sua utilização seja previamente aprovada pelo professor.

2- Etapas do trabalho:
a. Exploração dos dados
Realize uma análise exploratória da base escolhida e descreva o entendimento obtido sobre os dados. Pontos importantes a serem analisados:
- O problema de classificação investigado e sua relevância.
- A fonte dos dados e o link para acesso ou download.
- O número de instâncias e de atributos preditores.
- A descrição dos atributos, incluindo seus tipos e significados.
- A identificação do atributo classe e das classes existentes.
- A análise da distribuição das classes, verificando a existência de desbalanceamento.
- A identificação de valores ausentes, duplicatas, possíveis inconsistências e outras características relevantes.
- Gráficos ou tabelas que contribuam para a compreensão dos dados.

b. Pré-processamento e transformação dos dados
Escolher e justificar quais etapas de pré-processamento e transformação serão feitas nos dados para a prepará-los para os algoritmos selecionados. As decisões deverão ser justificadas com base nas características observadas na análise exploratória e nos requisitos dos algoritmos. Ex: normalização ou re-escala dos dados, substituição/remoção de valores ausentes, agregação de dados, amostragem, etc. Lembre-se alguns pré-

processamentos ou transformações são comuns a todos os algoritmos, outros são específicos para o algoritmo usado.

c. Algoritmos de classificação

Usar quatro algoritmos de classificação nas bases de dados escolhidas, sendo que pelo menos dois deles devem ser algoritmos que não foram vistos em sala de aula.

Para esta etapa, os estudantes poderão utilizar uma ferramenta de mineração de dados (como por exemplo, o *Weka*), poderão utilizar implementações prontas dos algoritmos disponíveis na Internet, usar implementações disponíveis em pacotes nas diferentes linguagens de programação (ex: *scikit learn* no *Python*, pacotes da linguagem R, etc.), buscar por implementações dos algoritmos em repositórios de código, implementar os seus próprios algoritmos.

Para cada algoritmo, deverão ser realizadas as seguintes atividades:

I. Descrever o funcionamento dos algoritmos. Lembre-se, o algoritmo não estudado deve ser descrito detalhadamente, incluindo um pseudocódigo que explique em linhas gerais o seu funcionamento.
II. Justificar sua escolha para o problema investigado.
III. Identificar e justificar os principais parâmetros utilizados.
IV. Testar pelo menos duas configurações diferentes de parâmetros.
V. Explicar quais etapas de pré-processamento foram necessárias para sua aplicação.

d. Planejamento experimental e avaliação dos algoritmos

Defina uma estratégia de avaliação que permita comparar os três algoritmos de maneira justa. Para isso, uma estratégia de divisão da base de dados em treino e teste deve ser escolhida. Além disso, pelo menos duas medidas de avaliação deverão ser usadas de acordo com as características do problema. É importante também apresentar a matriz de confusão obtida pelos classificadores bem como a fórmula das medidas de avaliação usadas.

A tarefa consiste em avaliar o desempenho dos quatro algoritmos de classificação em uma base de dados usando as medidas de avaliação escolhidas. É muito importante apresentar uma tabela comparativa de resultados.

É importante testar diferentes parametrizações dos algoritmos. Pelos menos duas parametrizações para cada algoritmos devem ser testadas. Ex: dois valores diferentes de K para o KNN. Discuta como foi feita a preparação da base de dados para testar as parametrizações dos algoritmos e a comparação dos algoritmos entre si. Algumas questões para ajudar na escrita desta seção:

- Qual algoritmo apresentou o melhor desempenho? A resposta depende da medida de avaliação utilizada?
- A alteração dos parâmetros modificou os resultados?
- Os algoritmos apresentaram comportamentos diferentes em relação aos erros de classificação?
- O desbalanceamento das classes, caso exista, influenciou a avaliação?
- Quais características da base de dados podem explicar as diferenças observadas?
- Qual modelo você recomendaria para o problema investigado? Justifique sua resposta considerando os resultados e as características da aplicação.

3- Entrega do relatório:

O grupo deverá entregar um relatório em PDF pelo Microsoft Teams, contendo:

I. Introdução e objetivos: contextualização do problema e objetivos do trabalho.

II. Descrição da base de dados: fonte, características, atributos, classes e análise exploratória.

III. Metodologia: pré-processamento, ferramentas, algoritmos, parâmetros e estratégia de avaliação e medidas usadas.

IV. Resultados e discussão: tabelas comparativas, medidas de avaliação e matrizes de confusão, interpretação crítica dos resultados e justificativa do modelo recomendado.

V. Conclusões: principais aprendizados, limitações do experimento e possíveis melhorias.

VI. Referências: fontes dos dados, bibliotecas, ferramentas e trabalhos utilizados.

4- Uso de ferramentas de Inteligência Artificial Generativa

O grupo deverá declarar se utilizou ferramentas de inteligência artificial generativa (LLMs), informando:

- O nome das ferramentas utilizadas.
- A finalidade do uso e as etapas do trabalho em que foram empregadas.
- Quais foram os prompts utilizados.
- Como as respostas produzidas foram verificadas.

O uso dessas ferramentas não substitui a necessidade de compreender, executar e interpretar os experimentos. Os integrantes deverão ser capazes de explicar as decisões metodológicas e os resultados apresentados no relatório.

5- Regras

a. Não serão aceitos trabalhos atrasados. Se o grupo não entregar o trabalho no dia combinado, ele receberá nota zero.
b. A professora em hipótese alguma verificará ou ajudará na construção do código fonte.
c. A professora poderá tirar dúvidas conceituais sobre o trabalho em horário de aula ou horário extra-classe.
d. A interpretação dos resultados e o entendimento dos algoritmos fazem parte da avaliação e devem ser realizados pelos estudantes.
e. Caso a professora identifique que o grupo usou LLMs sem a devida citação, todos os envolvidos receberão nota zero.
f. A nota da apresentação sobre o trabalho será um valor entre 0 e 1 que pondera a nota do trabalho.
g. Cada grupo deve preparar um pequeno conjunto de slides para apresentar em aula durante as aulas dedicadas ao trabalho.

6- Lista de bases de dados a serem usadas

1. Online Shoppers Purchasing Intention - Acessar base
2. Dry Bean - Acessar base
3. Bank Marketing - Acessar base
4. Default of Credit Card Clients - Acessar base
5. Phishing Websites - Acessar base
6. Predict Students' Dropout and Academic Success - Acessar base
7. Car Evaluation - Acessar base
8. Image Segmentation - Acessar base
9. Occupancy Detection - Acessar base
10. Statlog (German Credit Data) – Acessar base

11. Estimation of Obesity Levels Based on Eating Habits and Physical Condition – Acessar base
12. MAGIC Gamma Telescope – Acessar base
13. Drug Consumption – Acessar base
14. Iranian Churn – Acessar base
15. Assessing Mathematics Learning in Higher Education – Acessar base
16. Clickstream Data for Online Shopping – Acessar base
17. Room Occupancy Estimation – Acessar base
18. Yeast – Acessar base
19. In-Vehicle Coupon Recommendation – Acessar base
20. Bar Crawl: Detecting Heavy Drinking – Acessar base
21. Single Elder Home Monitoring: Gas and Position – Acessar base
22. Gas Turbine CO and NOx Emission Data Set – Acessar base
23. BEED: Bangalore EEG Epilepsy Dataset – Acessar base
24. HTRU2 – Acessar base
25. In-Vehicle Coupon Recommendation – Acessar base